

基于度量学习和 Vision Transformer 的 细粒度图像聚类方法

张铭 2023192004

2026 年 7 月

摘要

细粒度图像聚类是计算机视觉领域的重要课题，旨在将同一物种或类别的子类图像进行无监督聚合。本文基于 PyTorch 框架，采用 Vision Transformer 架构的 MegaDescriptor-B-224 作为骨干网络，结合度量学习中的 CircleLoss 损失函数和余弦相似度度量，设计并训练了一个面向细粒度图像聚类任务的深度学习模型。在模型结构上，本文提出了一种带有残差连接的投影头结构，在保留骨干网络预训练特征的同时对特征进行微调。在训练策略上，采用冻结骨干网络、分组学习率、余弦退火调度和混合精度训练等技术，并使用 MPerClassSampler 进行类别均衡采样。在猫只个体识别数据集上的实验结果表明，本文方法取得了良好的聚类效果，最优 NMI 达到 0.8761，Recall@1 达到 0.6903，验证了所提方法的有效性。

目录

1 引言	3
2 相关方法	3
2.1 整体框架	3
2.2 骨干网络：MegaDescriptor-B-224	3
2.3 投影头与残差连接	4
2.4 度量学习：CircleLoss	4
2.5 类别均衡采样	5
2.6 聚类与评估方法	5
2.6.1 HDBSCAN 密度聚类	5
2.6.2 评估指标	6
3 实验	6
3.1 实验设置	6
3.1.1 数据集	6
3.1.2 数据增强	6
3.1.3 训练参数	6
3.2 训练策略	6
3.3 实验结果与分析	7
3.3.1 训练过程分析	7
3.3.2 最终结果	8

3.3.3 结果分析	8
4 总结	9

1 引言

细粒度图像分析是计算机视觉中的一个重要分支，其目标是对某一类物体的子类进行精细区分，例如不同品种的狗、不同型号的飞机、不同个体的动物等。与传统的图像分类任务不同，细粒度分类任务中不同类别之间的视觉差异极其微小，往往仅体现在局部区域的细微纹理、颜色或形状差异上，这对特征提取能力提出了极高的要求。

近年来，深度学习技术在细粒度图像识别领域取得了显著进展。卷积神经网络（CNN）和 Vision Transformer（ViT）等深度模型能够自动学习层次化的视觉特征表示，为实现高质量的细粒度图像分析提供了坚实基础。与此同时，度量学习（Metric Learning）作为一种有效的特征学习范式，通过将同一类别的样本在嵌入空间中拉近、不同类别的样本推远，为聚类 and 检索任务提供了强有力的工具。

在动物个体识别（Animal ReID）这一典型细粒度任务中，要求模型能够仅凭外观特征识别出不同的个体动物。例如，对于猫只个体识别，不同猫之间可能存在相似的花纹和体型，而同一只猫在不同光照、角度下的照片又可能存在较大差异，这使得该任务极具挑战性。

本文基于 PyTorch 深度学习框架，设计并训练了一个用于细粒度图像聚类的模型。本文的主要贡献如下：

1. 采用 HuggingFace 上的 MegaDescriptor-B-224（基于 ViT 架构的预训练模型）作为骨干特征提取网络，充分利用其在动物识别任务上的预训练知识。
2. 设计了一种带有残差连接的轻量级投影头结构，在保持骨干网络原始特征质量的同时，通过微调适配特定任务。
3. 引入 CircleLoss 作为度量学习损失函数，结合余弦相似度度量，有效提升了嵌入空间的判别性。
4. 采用丰富的训练策略，包括冻结微调、分组学习率、余弦退火、混合精度训练、类别均衡采样和数据增强等，实现了稳定高效的训练过程。
5. 使用 HDBSCAN 密度聚类算法对提取的特征进行聚类，并采用调整兰德指数（ARI）、归一化互信息（NMI）和 Recall@K 等指标进行全面评估。

实验在猫只个体识别数据集上进行，结果验证了所提方法的有效性，在多个评估指标上均取得了良好的表现。

2 相关方法

2.1 整体框架

本文设计的细粒度图像聚类系统主要由四个阶段组成：数据预处理与增强、特征提取与嵌入学习、度量学习优化、聚类与评估。整体流程如图1所示。

2.2 骨干网络：MegaDescriptor-B-224

本文采用 MegaDescriptor-B-224 作为骨干特征提取网络。MegaDescriptor 是基于 Vision Transformer（ViT）架构构建的大规模动物识别预训练模型，由 BVRA 团队在 HuggingFace 上开源发




图 1: 系统整体流程示意图

布。该模型在包含数万种动物类别的大规模数据集上进行了预训练，具备强大的动物视觉特征提取能力。

MegaDescriptor-B-224 的特点如下：

- 采用 ViT-Base 架构，将图像切分为 16×16 的 Patch，通过 Transformer 编码器进行全局自注意力建模。
- 在动物识别领域的大规模数据集上进行了充分预训练，能够提取具有高度判别性的动物外观特征。
- 输出维度为 768 维的特征向量，为后续的投影头提供了丰富的语义信息。

使用预训练模型可以显著减少对标注数据的需求，加速训练收敛，提高最终性能。

2.3 投影头与残差连接

为了将骨干网络提取的 768 维特征映射到更适合度量学习的 256 维嵌入空间，本文设计了一个带有残差连接的投影头模块。投影头的结构如式1所示。

$$\mathbf{e} = \text{L2Norm}(\mathbf{W}_{\text{res}}\mathbf{f} + 0.05 \cdot \text{MLP}(\mathbf{f})) \quad (1)$$

其中 $\mathbf{f} \in \mathbb{R}^{768}$ 为骨干网络提取的特征， $\mathbf{W}_{\text{res}} \in \mathbb{R}^{768 \times 256}$ 为残差线性映射，MLP 为三层全连接网络（ $768 \rightarrow 512 \rightarrow 256$ ，含 BatchNorm、ReLU 和 Dropout）。最终输出进行 L2 归一化，得到单位超球面上的嵌入向量。

残差连接的设计思想是：保留骨干网络原始特征的 100% 信息（通过线性映射），同时仅用投影头做 5% 的微调修正。这种设计既能充分利用预训练特征的质量，又能为特定任务提供灵活的自适应能力。实验表明，这种设计比单独使用投影头或单独使用残差映射取得了更好的效果。

2.4 度量学习：CircleLoss

度量学习的核心目标是学习一个嵌入空间，使得同类样本距离近、异类样本距离远。本文采用 CircleLoss 作为损失函数，其定义如式2所示。

$$\mathcal{L}_{\text{circle}} = \log \left[1 + \sum_{j \in \Omega_n} e^{\gamma(s_n^j - \Delta_n)} \sum_{i \in \Omega_p} e^{\gamma(-s_p^i + \Delta_p)} \right] \quad (2)$$

其中 s_p 和 s_n 分别为正样本对和负样本对的余弦相似度, Ω_p 和 Ω_n 分别表示正负样本对集合, γ 为缩放因子 (本文设为 256), $\Delta_p = 1 - m$ 和 $\Delta_n = m$ 为边界参数 ($m = 0.25$)。

与传统 TripletLoss 相比, CircleLoss 具有以下优势:

- 对正负样本对的优化权重进行自适应调整, 使得对已经分离很好的样本对给予较小的梯度, 而对边界附近的样本对给予较大的梯度。
- 优化目标更加灵活, 不要求严格的边界条件, 收敛更加平滑。
- 在细粒度分类任务中表现出更优的嵌入质量。

本文使用余弦相似度 (CosineSimilarity) 作为距离度量, 相比欧氏距离, 余弦相似度对特征向量的尺度不敏感, 更适合处理归一化的嵌入向量。

2.5 类别均衡采样

在细粒度聚类任务中, 不同类别的样本数量往往不均衡。为了解决这一问题, 本文采用 MPer-ClassSampler 采样策略, 即每个 Batch 中保证每个类别选取 m 个样本 (本文 $m=6$)。这种策略确保:

- 每个 Batch 中各类别样本数量均衡, 避免模型偏向多数类。
- 保证每个 Batch 内都有足够的正样本对和负样本对, 有利于度量学习损失函数的优化。
- 提高了训练效率, 减少了无效的样本对。

2.6 聚类与评估方法

2.6.1 HDBSCAN 密度聚类

在提取图像嵌入后, 本文采用 HDBSCAN (Hierarchical Density-Based Spatial Clustering of Applications with Noise) 算法进行聚类。HDBSCAN 是一种基于密度的层次聚类算法, 相比传统的 K-Means 算法, 其优势在于:

- 不需要预先指定聚类数量, 能够自动发现数据中的聚类结构。
- 能够识别和剔除噪声点, 将不属于任何聚类的样本标记为-1。
- 对非球形分布的数据簇具有良好的适应性。

本文设置最小簇大小 (min_cluster_size) 为 3, 聚类选择容忍度 (cluster_selection_epsilon) 为 0.0。

2.6.2 评估指标

本文采用多种指标对聚类 and 检索性能进行全面评估：

- **ARI (Adjusted Rand Index)**: 衡量聚类结果与真实标签的相似度，取值范围 $[-1, 1]$ ，越接近 1 表示聚类效果越好，且对随机聚类的期望值为 0。
- **NMI (Normalized Mutual Information)**: 衡量聚类结果与真实标签之间的互信息，取值范围 $[0, 1]$ ，越接近 1 表示聚类效果越好。
- **Recall@K**: 在检索任务中，从嵌入空间找出与查询样本最相似的 K 个样本，计算其中属于同类的比例。本文采用 R@1 和 R@5 两个指标。
- **噪声比例 (Noise Ratio)**: HDBSCAN 标记为噪声 (-1) 的样本占比，反映了聚类算法对数据的覆盖程度。

3 实验

3.1 实验设置

3.1.1 数据集

实验采用猫只个体识别数据集，训练集和验证集分别包含不同数量的猫只个体图像。每张图像均为 RGB 彩色图像，尺寸不一。数据集通过 mapping.csv 文件提供图像文件名与个体 ID 的对应关系。

3.1.2 数据增强

为了提升模型的泛化能力和鲁棒性，本文采用了丰富的数据增强策略：

- 随机 Resize 裁剪 (RandomResizedCrop): 将图像缩放到 256×256 后随机裁剪到 224×224 ，裁剪比例范围为 $0.7 \sim 1.0$ 。
- 随机水平翻转 (RandomHorizontalFlip): 概率为 0.5。
- 颜色抖动 (ColorJitter): 调整亮度 (0.2)、对比度 (0.15)、饱和度 (0.15) 和色调 (0.05)。
- 随机旋转 (RandomRotation): 旋转角度范围为 $\pm 10^\circ$ 。
- 标准化 (Normalize): 使用 ImageNet 均值和标准差进行归一化。
- 随机擦除 (RandomErasing): 概率为 0.5，擦除区域比例为 $0.02 \sim 0.2$ 。

验证集仅使用 Resize 到 256 后中心裁剪到 224，以及标准化处理。

3.1.3 训练参数

主要训练参数如表1所示。

表 1: 主要训练参数配置

参数名称	配置值
嵌入维度	256
Batch 大小	32
训练轮数	60
初始学习率	1×10^{-4}
骨干学习率比例	0.05
损失函数	CircleLoss ($m = 0.25, \gamma = 256$)
距离度量	余弦相似度
优化器	AdamW
学习率调度	CosineAnnealing
采样策略	MPerClassSampler ($m = 6$)
混合精度	AMP (自动混合精度)
梯度裁剪	<code>max_norm=1.0</code>
验证间隔	2 轮

3.2 训练策略

本文采用分阶段训练策略：

1. **冻结阶段：**首先冻结骨干网络的所有参数，仅训练投影头（包括 MLP 和残差映射）。这一阶段让投影头学习如何将预训练特征映射到度量学习空间。
2. **分组学习率：**为骨干网络和投影头设置不同的学习率。骨干网络学习率为基础学习率的 0.05 倍 (5×10^{-6})，投影头学习率为基础学习率的 0.5 倍 (5×10^{-5})。这种设置允许投影头较快适应，同时防止骨干网络参数发生剧烈变化。
3. **余弦退火调度：**学习率按照余弦函数从初始值逐渐衰减到 0，使得训练前期学习率较大以便快速收敛，后期学习率较小以便精细微调。
4. **混合精度训练：**使用 PyTorch 的自动混合精度（AMP）技术，在保持模型精度的同时减少显存占用并加速训练。
5. **梯度裁剪：**设置梯度最大范数为 1.0，防止梯度爆炸。

3.3 实验结果与分析

3.3.1 训练过程分析

图2展示了训练过程中损失函数和各项评估指标的变化趋势。

从训练曲线上可以观察到：

1. **损失函数：**训练损失在整个训练过程中持续下降，从初始的较高值逐渐降低并趋于平稳，说明模型在学习过程中不断优化嵌入空间的质量。
2. **聚类指标：**ARI 和 NMI 在训练初期增长迅速，随后进入平稳期并略有波动。这表明模型能够快速学习到有区分性的特征表示。




图 2: 训练曲线（20260710 训练结果）

3. **检索指标:** Recall@1 和 Recall@5 同样呈现先快速增长后趋于平稳的趋势。R@5 始终显著高于 R@1，说明虽然最相似样本不一定属于同类，但前 5 个最相似样本中包含正确类别的概率较高。
4. **学习率与噪声比例:** 学习率按照余弦曲线平滑衰减，噪声比例随训练进程逐步降低，表明嵌入空间的聚类结构变得越来越清晰。

3.3.2 最终结果

表2列出了最佳模型在验证集上的最终评估结果（本实验中最佳 ARI 与最佳 NMI 对应同一模型）。

表 2: 验证集最终评估结果

模型	ARI	NMI	R@1	R@5	噪声比例
最佳模型	0.7501	0.8761	0.6903	0.8545	80.99%

从结果可以看出：

- NMI 指标达到了 0.8761 的高水平，说明模型提取的嵌入具有良好的聚类结构，与真实标签的互信息较高。
- R@5 达到了 0.8545，说明在前 5 个检索结果中，有较大概率包含同类样本，验证了模型在实际检索任务中的有效性。
- ARI 指标达到了 0.7501，表明聚类结果与真实标签具有高度一致性。
- 噪声比例约为 80.99%，表明 HDBSCAN 将约 81% 的样本识别为噪声点，仅约 19% 的样本被分配到具体簇中。这主要是因为 HDBSCAN 的保守策略倾向于将不确定样本标记为噪声，结合后续的解冻微调可能进一步降低噪声比例。

3.3.3 结果分析

本文方法取得较好效果的原因可归纳为以下几点：

1. **强大的预训练骨干:** MegaDescriptor-B-224 在动物识别领域的大规模数据上预训练，提供了高质量的初始特征表示。

2. **有效的度量学习**: CircleLoss 结合余弦相似度, 在嵌入空间中形成了类内紧凑、类间分离的分布结构。
3. **合理的训练策略**: 冻结微调、分组学习率和余弦退火等策略确保了训练的稳定性并最终性能。
4. **丰富的增强手段**: 数据增强增加了训练数据的多样性, 提升了模型的泛化能力。

同时, 也存在一些可以进一步改进的方向:

1. **解冻骨干网络**: 在训练后期适度解冻骨干网络的最后几个层, 可以进一步提升特征表示能力。
2. **更优的聚类算法**: 探索使用更先进的聚类方法或对 HDBSCAN 参数进行调优, 以降低噪声比例。
3. **集成学习**: 融合多个训练周期的模型特征, 可能获得更稳定 and 更优的聚类结果。
4. **数据扩展**: 增加更多高质量的标注数据, 尤其是在困难样本上, 有助于提升模型性能。

4 总结

本文针对细粒度图像聚类任务, 基于 PyTorch 框架设计并实现了一套完整的解决方案。在模型层面, 采用 MegaDescriptor-B-224 作为骨干网络, 结合带有残差连接的投影头和 CircleLoss 度量学习损失函数, 构建了一个有效的特征嵌入学习模型。在训练层面, 采用冻结微调、分组学习率、余弦退火、混合精度训练、MPerClassSampler 均衡采样和丰富的数据增强等技术手段, 确保了训练的高效性和稳定性。在评估层面, 使用 HDBSCAN 密度聚类算法结合 ARI、NMI、Recall@K 和噪声比例等多维度指标, 对模型性能进行了全面评估。

实验结果表明, 本文方法能够在猫只个体识别数据集上取得良好的聚类和检索效果, 最佳模型上 ARI 达到 0.7501, NMI 达到 0.8761, R@1 达到 0.6903, R@5 达到 0.8545。这些结果验证了将 Vision Transformer 预训练模型与度量学习相结合解决细粒度图像聚类任务的有效性。

尽管取得了一定的成果, 本文方法仍存在改进空间。未来的工作可以考虑解冻骨干网络进行端到端微调、探索更优的聚类算法、引入注意力机制增强局部特征提取能力, 以及在更大规模的数据集上进行验证。